

Alunos: Miguel Drozino 23155078-2
Ricardo Guilhen 23013569-2
Micaela Dorneles 23150068-2
Igor Costa - 23215764-2
Nathan Rodrigues - 23025003-2

1 - Conceitual - Importância da Preparação

Se os dados de entrada contêm inconsistências, ou variáveis irrelevantes, o algoritmo aprenderá esses defeitos em vez do padrão real do negócio que realmente afeta o resultado final desejado. Até porque temos uma infinidade de dados, de tipos diferentes, com numerais ou caracteres, que muitas vezes não têm correlação.

2 - Valores Ausentes

a) Possíveis estratégias para tratar esses valores:

Usar métricas como correlação e covariância, descartar os dados, suavizar os dados usando alfa, amostragem, conversão de dados numéricos para simbólicos, normalização, etc...

b) Em quais situações remover registros é inadequado?

Se a quantidade de registros com valores ausentes for muito grande, e se os valores forem “únicos”, tiverem grande impacto no resultado final.

3 - Normalização x Padronização

(Min - Max)

Quando os dados têm formatos irregulares, pendem mais para um lado, eles não estão distribuídos, daí nós usamos da reescala para definir um intervalo, geralmente de 0 a 1, para classificar os menores e maiores valores.

(Z-score)

É usado quando os dados são distribuídos, ou seja a variância é bem visualizável, fazendo uso da média, e do desvio padrão.

4 - Dados Categóricos

a) Como transformar essa variável para uso em um modelo de Machine Learning?

Resposta: A maneira mais adequada de transformar é utilizando uma técnica chamada One-Hot. Como o clima é uma variável categórica nominal, o One-Hot Encoding cria uma nova coluna binária (0 ou 1) para cada categoria possível.

b) Qual problema pode ocorrer se utilizarmos apenas codificação numérica simples (0,1,2)?

Resposta: O principal problema de usar uma codificação numérica direta é que o algoritmo de Machine Learning pode deduzir uma relação matemática de ordem ou grandeza que não existe na vida real.

5 - Overfitting e separação de dados

Dividimos o dataset para não usar os mesmos dados para treinar e comparar os resultados, então dividimos o dataset em partes, com o treino usando aproximadamente 80% da base, e o de teste 20%, e o de validação algo que fique entre os dois, aproximadamente 10%.

O que acontece se utilizarmos o conjunto de teste durante o treinamento?

O modelo terá uma previsibilidade pior, pois o conjunto de teste geralmente é 20% da base de dados, e o de treino 80%.

Balanceamento de Classes

6 - Considere um problema onde:

- 95% das amostras pertencem à classe A
- 5% pertencem à classe B

a) Qual problema pode ocorrer?

O principal problema é o bias (viés de modelo) em favor da classe majoritária. O algoritmo pode atingir uma acurácia muito alta (95%) simplesmente “chutando” que todos os exemplos pertencem à classe A, ignorando completamente a classe B. Isso é perigoso porque, em muitos casos (detecção de fraudes ou doenças), a classe minoritária é justamente a que mais nos interessa identificar.

b) Cite duas técnicas para tratar esse desbalanceamento.

Resposta:

1. Oversampling: Consiste em criar novos exemplos sintéticos da classe minoritária (classe B) para equilibrar a proporção com a classe majoritária.
2. Undersampling: Consiste em remover aleatoriamente exemplos da classe majoritária (classe A) até que as quantidades fiquem equilibradas.

7 - Detecção de Outliers

a) O que são outliers?

Resposta: Outliers são instâncias ou valores em um conjunto de dados que se distanciam drasticamente do padrão geral das outras observações. Eles são dados extremos que parecem ter sido gerados por um processo diferente ou por erros de medição, não se encaixando na distribuição normal da maioria das amostras.

b) Quando removê-los pode prejudicar o modelo?

Resposta: Remover outliers de forma cega pode destruir o desempenho do modelo quando esses pontos extremos contêm informações cruciais sobre o problema que você quer resolver. Isso ocorre principalmente em dois cenários:

Quando o objetivo é prever a própria anomalia: Em sistemas de detecção de fraude em cartões de crédito, invasões de rede ou diagnósticos de doenças raras, o outlier é exatamente o alvo. Se você removê-lo da base de treino por achá-lo "fora do padrão", o modelo nunca aprenderá a identificar uma fraude ou uma doença.

Quando representam a realidade do negócio: Às vezes o outlier não é um erro de digitação, mas um fenômeno real (ex: um pico de vendas gigantesco na Black Friday). Remover esse dado fará com que o modelo não consiga prever cenários extremos legítimos no mundo real.

c) Um método estatístico para detectá-los

Resposta: Um dos métodos estatísticos mais clássicos e simples é o Z-Score (Escore Padrão). O Z-Score calcula a quantos desvios padrões um determinado dado está de distância da média de todo o conjunto. A fórmula é:

$$Z = \frac{x - \mu}{\sigma}$$

Onde:

- x é o valor do dado sendo analisado.
- μ é a média do conjunto de dados.
- σ é o desvio padrão.

Como funciona na prática: Em uma distribuição normal, se o valor absoluto do Z-Score de um dado for maior que 3 (ou seja, ele está

a mais de 3 desvios padrões de distância da média), ele é estatisticamente classificado como um outlier.

Feature Engineering

8 - Dado o dataset:

`data_nascimento`

Explique por que criar a variável `idade` pode ser melhor do que usar diretamente a data de nascimento.

Resposta:

1. Redução de Dimensionalidade/Complexidade: uma data completa contém dia, mês e ano. Para um modelo de IA, interpretar a relação temporal entre datas é muito mais difícil do que processar um único valor numérico (inteiro) que representa a idade.
2. Sinal direto: a `idade` geralmente tem uma correlação mais direta e linear com o que se deseja prever (ex: perfil de consumo, risco de saúde ou probabilidade de crédito). Manter a data de nascimento exigiria que o modelo “aprendesse” a subtrair a data atual da data de nascimento por conta própria, o que consome capacidade computacional desnecessária.
3. Generalização: a data de nascimento é uma informação muito específica. Se você treinar o modelo com alguém que nasceu em 15/03/1990, ele pode ter dificuldade em generalizar para alguém de 16/03/1990. Se ambos forem convertidos para “34 anos”, o modelo agrupa esses indivíduos de forma mais eficiente.

9 - Pipeline de pré-processamento

Descreva um pipeline completo de preparação para um dataset que contém:

- Valores ausentes
- Dados categóricos
- Variáveis com escalas diferentes

- Classes desbalanceadas

Resposta:

Resumo de fluxo:

Input => Imputação => Encoding => Scaling => Balancing => Modelo de IA

O primeiro passo deve ser sempre lidar com os lacunas no dataset.

1. Limpeza de dados (tratamento de valores ausentes)

- Técnica: imputação. Para variáveis numéricas, usa-se a média ou mediana; para categóricas, a moda (valor mais frequente). Em casos críticos, pode-se remover a linha ou a coluna inteira se a falta de dados for excessiva.

2. Codificação de dados categóricos (encoding)

Transformar textos em números para que o modelo consiga processar.

- Técnica: One-Hot Encoding (para categorias sem ordem, como cores) ou Ordinal Encoding (para categorias com hierarquia, como “júnior, pleno, sênior”).

3. Escalonamento de variáveis (feature scaling)

Colocar todas as variáveis numéricas na mesma “unidade de medida”.

- Técnica: Padronização (StandardScaler) para deixar os dados com média 0 e desvio padrão 1, ou Normalização (MinMaxScaler) para colocar os valores entre 0 ou 1.

4. Tratamento de classes desbalanceadas

Ajustar a proporção entre as classes antes de iniciar o treinamento.

- Técnica: SMOTE (Oversampling) para criar dados sintéticos da classe minoritária ou Random Undersampling para reduzir a classe majoritária.

10 - Estudo de caso aplicado

Variáveis:

- renda_mensal
 - idade
 - estado_civil
 - número_de_dependentes
 - histórico_de_inadimplência
- Calcular as correlações desvio-padrão, etc (amostragem)
 - Remover dados extremos, com variância exagerada
 - Transformar dados: exemplos: idades -> (0-20 anos) (20-50)...
 - Renda mensal: faixas de renda -> (1500- 3000) (3000-5000)
 - Isso também para as outras métricas para facilitar a comparação para os modelos probabilísticos
 - Balanceamento das classes para que não tenha apenas um resultado o tempo todo
 - Separação dos datasets de treinamento e teste (80% e 20%) sendo que boa parte dos tratamentos são apenas no dataset de treino, para termos um resultado teste real.